

Analyse des Risques IA

Document interne confidentiel - Département Innovation & IA

Mise à jour : Mai 2026 | Priorité : Élevée | Statut : Approuvée par la Direction

Le déploiement à grande échelle de systèmes multi-agents soulève des défis critiques en matière de fiabilité et de sécurité que notre département doit impérativement anticiper. Le risque majeur identifié à ce jour concerne les hallucinations des modèles génératifs. Ces erreurs factuelles, si elles sont intégrées dans des rapports stratégiques, pourraient induire la direction en erreur. Le problème fondamental réside dans l'absence actuelle de mécanismes de validation automatique pour vérifier les réponses générées par nos IA.

Sur le plan de la sécurité de l'information, nous faisons face à un risque élevé de fuite de données sensibles (propriété intellectuelle, données clients) via les prompts envoyés aux modèles hébergés sur le cloud public. Il est impératif de rappeler que la conformité au RGPD est une contrainte réglementaire stricte et non négociable pour l'ensemble de nos pipelines de données. Un autre risque technique majeur est notre potentielle dépendance excessive (vendor lock-in) à un seul fournisseur de LLM, ce qui pourrait nous exposer à des hausses de prix brutales ou à des interruptions de service.

Pour mitiger ces menaces, le département recommande l'implémentation immédiate d'une approche "policy-as-code", permettant de bloquer automatiquement les requêtes non conformes. Nous exigeons également la mise en place de boucles de validation au sein de nos systèmes RAG, où un agent "critique" vérifiera systématiquement les sources des agents "rédacteurs". L'objectif ultime de sécurité pour la fin de l'année est de garantir une traçabilité complète et inaltérable de tous les workflows IA.