

Stack Technique Actuelle

Document interne confidentiel - Département Innovation & IA

Mise à jour : Mai 2026 | Priorité : Élevée | Statut : Approuvée par la Direction

Notre environnement technologique actuel repose sur des fondations solides, mais nécessite des évolutions pour supporter notre transition vers des systèmes autonomes. L'intégralité de notre infrastructure cloud est actuellement hébergée sur Microsoft Azure, qui nous fournit la puissance de calcul et la sécurité réseau nécessaires à nos opérations. Pour notre système RAG, nous avons standardisé l'utilisation de ChromaDB comme base de données vectorielle (Vector database), permettant une recherche sémantique rapide et efficace au sein de nos embeddings documentaires.

LangChain demeure notre framework principal pour la construction de nos applications IA, servant de pont entre nos bases de données, nos outils et les modèles de langage. Dans une optique de résilience et d'optimisation des coûts, nous avons adopté une stratégie multi-modèles (LLMs) : nous utilisons conjointement GPT-4 pour les tâches nécessitant un raisonnement complexe, Claude pour les analyses de contextes documentaires massifs, et Mistral pour les requêtes plus simples et économiques.

En matière de stockage de données, notre architecture s'appuie sur un système hybride combinant SharePoint pour les documents bureautiques vivants et un Data Lake Azure pour l'archivage massif et les logs. Le monitoring de notre infrastructure et de l'activité de nos modèles est assuré par la combinaison de Grafana et Prometheus, offrant des tableaux de bord en temps réel. La limitation architecturale majeure de notre stack actuelle réside dans l'absence d'une véritable orchestration multi-agents avancée ; nos processus actuels sont limités à des pipelines Python séquentiels et rigides, ce qui justifie nos investissements futurs vers des solutions orientées graphes et événements.