

# RAPPORT STRATÉGIQUE IA

## Executive Summary

L'analyse des tendances externes (2025-2026) montre une adoption rapide des frameworks multi-agents (LangGraph 32k★, AutoGen 58k★), des solutions RAG-aaS/Graph-RAG permettant de réduire le temps de mise en production d'environ 30 %, ainsi que des plateformes cloud spécialisées offrant 50-70 % d'économie d'OPEX par rapport aux hyperscalers. La gouvernance IA, la détection d'hallucinations et l'usage de modèles ouverts émergent comme facteurs de différenciation et de conformité.

En interne, le projet repose actuellement sur un PoC LangGraph + 3 agents (prévu Q1 2026) visant un workflow complet de 5 agents d'ici Q3-Q4 2026, avec un RAG basique via ChromaDB et une atténuation des hallucinations par des cycles conditionnels. Aucun budget, aucun cadre de gouvernance, aucun indicateur de performance (KPI) ni détail sur le LLM utilisé n'est spécifié. AutoGen n'est pas intégré malgré son adoption par 15 % des startups IA en 2026.

Les écarts identifiés portent sur le choix du framework, la profondeur du RAG, la maîtrise des coûts infrastructure, la gouvernance et la mesure d'impact. En réponse, le rapport propose des actions prioritaires : mise en place d'une gouvernance IA, analyse de coûts LLM propriétaire vs ouverts, enrichissement du RAG avec détection d'hallucinations et éventuel Graph-RAG, évaluation de plateformes cloud spécialisées, expérimentation d'AutoGen/CrewAI, définition de KPI et jalons de mise en production, enfin extension vers des cas d'usage à valeur ajoutée (visualisations interactives, surveillance de marché).

## Tendances clés

- Frameworks multi-agents : LangGraph (≈ 32 k★) et AutoGen (≈ 58 k★) en forte adoption ; CrewAI et AgentCore émergents.
- RAG & hallucinations : RAG-aaS + Graph-RAG (Neo4j) réduisent le temps de mise en prod d'environ 30 % ; détecteurs d'hallucinations deviennent standards.
- Infrastructure & coût : Plateformes cloud spécialisées (Railway, AWS SageMaker, GCP Vertex AI) offrent 50-70 % d'économie d'OPEX vs hyperscalers ; Ollama + modèles locaux (Llama 3, Mistral) pour déploiement on-prem/edge.
- Gouvernance & conformité : Cadres tels que Microsoft AI Governance Framework, SOC 2, HIPAA intégrés aux plateformes (Langfuse, Clarity) ; outils open-source de sécurité (RAMPART, Clarity) pour tester les agents en dev.
- Modèles ouverts & concurrence : Goose, Opus 4.5, modèles Ollama offrent des performances proches de Claude Code gratuitement ; pression accrue sur les modèles propriétaires.
- Cas d'usage émergents : Agents web capables de générer des visualisations interactives ou de surveiller des marchés en temps réel ; sécurité des agents testée dès le dev (outils Microsoft).

## Analyse comparative (écarts internes vs externes)

| Axe                           | Écart interne                                                                                   | Opportunité associée                                                                                                                                                                                     | Risque / retard si non adressé                                                                                      |
|-------------------------------|-------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------------------------|
| Frameworks multi-agents       | Interne utilise uniquement LangGraph (3 agents → 5 agents) ; aucun recours à AutoGen ou CrewAI. | Tester AutoGen pour génération de code / automatisation de tests (adopté par 15 % des startups IA en 2026) ; combiner LangGraph (orchestration) + AutoGen (agents spécialisés) pour plus de flexibilité. | Risque de rester sur une solution moins optimisée pour certains use-cases (ex. génération de code, tests).          |
| RAG & hallucinations          | RAG basique via ChromaDB + cycles conditionnels ; pas de détecteur dédié ni de Graph-RAG.       | Ajouter un module de détection d'hallucinations (ex. AgentCore, vérification croisée) ; explorer Graph-RAG (Neo4j) pour réduire le temps de mise en prod d'environ 30 %.                                 | Sans détection robuste, le taux d'hallucination peut rester élevé → perte de confiance dans les rapports de veille. |
| Infrastructure & coût         | Dépendance à ChromaDB en prod ; aucun détail sur le coût LLM ou alternatives cloud-optimisées.  | Évaluer des plateformes spécialisées (Railway, SageMaker, Vertex AI) pour réduire l'OPEX de 50-70 % ; envisager déploiement hybride (modèles locaux Ollama pour faible latence, cloud pour pics).        | Risque de dépassement budgétaire si le coût des LLM propriétaires n'est pas maîtrisé.                               |
| Gouvernance & conformité      | Aucun cadre de gouvernance mentionné.                                                           | Adopter un framework de gouvernance IA (Microsoft AI Governance, ISO/IEC 42001) dès la conception ; mettre en place outils de traçabilité (Langfuse, Clarity) et validation (SOC 2, HIPAA si pertinent). | Exposition à des risques réglementaires, surtout si les rapports sont partagés avec des secteurs réglementés.       |
| Modèles ouverts & concurrence | LLM utilisé non spécifié (prob                                                                  |                                                                                                                                                                                                          |                                                                                                                     |